人工知能学会第二種研究会資料
セマンティックウェブとオントロジー研究会
SIG-SWO-064-05

社内知識の活用を支援する知識グラフ自動生成

Method for automatically generating knowledge graphs to utilize internal knowledge

福田悠貴 [1*]　仁禮和男 [1]　大西舞子 [1]　関根聡 [2]　松本裕治 [2]　古崎晃司 [2,3]
Yuki Fukuda[1],Kazuo Nirei[1],Maiko Onishi[1],Satoshi Sekine[2],Yuji Matsumoto[2],Kouji Kozaki[2,3]

[1] 株式会社アイシン
[1] AISIN CORPORATION
[2] 理化学研究所 革新知能統合研究センター
[2] RIKEN，Center for Advanced Intelligence Project
[3] 大阪電気通信大学
[3] Osaka Electro-Communication University

Abstract: To reduce development time, we are creating a chatbot system using Retrieval-Augmented Generation (RAG) to handle specialized inquiries. Challenges include the unfamiliarity of Large Language Model (LLM) with specific terms and the handling of ambiguous queries. We propose using a knowledge graph to supplement terms with explanations, synonyms, and hierarchical concepts. We developed a method using LLM to construct knowledge graphs for RAG more efficiently, maintaining accuracy while significantly reducing processing time compared to traditional methods. This paper details the methods for automating synonym and hierarchical relationship estimation using LLM.

1　はじめに

現代の急速な技術進化と市場の変化に対応するため，開発期間の短縮が求められている．その際のネックになっているのが，自身の専門分野とは異なる専門外の知識を扱う場合の対応である．現在，開発者は材料などの専門外の知識が必要な場合は異なる部署の専門家に問い合わせしており，回答を得るまでの時間が開発期間を延長させる要因となっている．

回答を得るまでの時間を短縮するため，我々は専門知識が記載されているドキュメントを用いた RAG[1] を活用し，問い合わせ自動回答可能なチャットボットシステムの開発を行っている．しかし，質問文に記載された専門用語を生成 AI が学習していない場合や，質問文の語句が具体的・曖昧過ぎることでドキュメントと表現が異なり検索が上手く行かない場合に，LLM が正しい回答を生成できないという課題が見つかった．例えば,「オイルに強いゴムを教えて」という質問文が入力された際に，ドキュメント内に「VMQ は耐鉱物油が良好」と記載された文章が回答で参照されない場合がある．なお，VMQ（ビニルメチルシリコーンゴム）はゴムの一種であり，鉱物油はオイルの一種である．

この課題に対処するため，質問文内で用いている語句に対し，知識グラフを用いて語句の説明文や上位下位概念や同義語の情報を補足する方法を検討している。知識グラフは図 1 のように，ノードには語句の説明文を付与し，エッジは同義語を表す same と上位下位概念を表す is-a のみの，最低限の構造で定義した．このような定義の知識グラフを活用することにより，チャットボットシステムの回答精度は約 7 割から約 8 割程度まで向上すると見込んでいる．

しかし，社内には膨大な技術文書が蓄積されているため，全ての技術文書を人が確認し，知識グラフを構築するのは非現実的である．そこで，我々は知識グラフ構築プロセスの自動化に取り組み，LLM を活用した手法を開発した．これにより，同義語や上位下位概念の関係性を効率的に推定し，構築コストを削減することが可能になった．本論文では LLM を活用した知識グラフ構築自動化手法の中でも特に同義語と上位下位概念の関係性推定手法について述べる．

*連絡先：株式会社アイシン
〒 448-8650 愛知県刈谷市朝日町二丁目 1 番地
E-mail: yuki.fukuda@aisin.co.jp

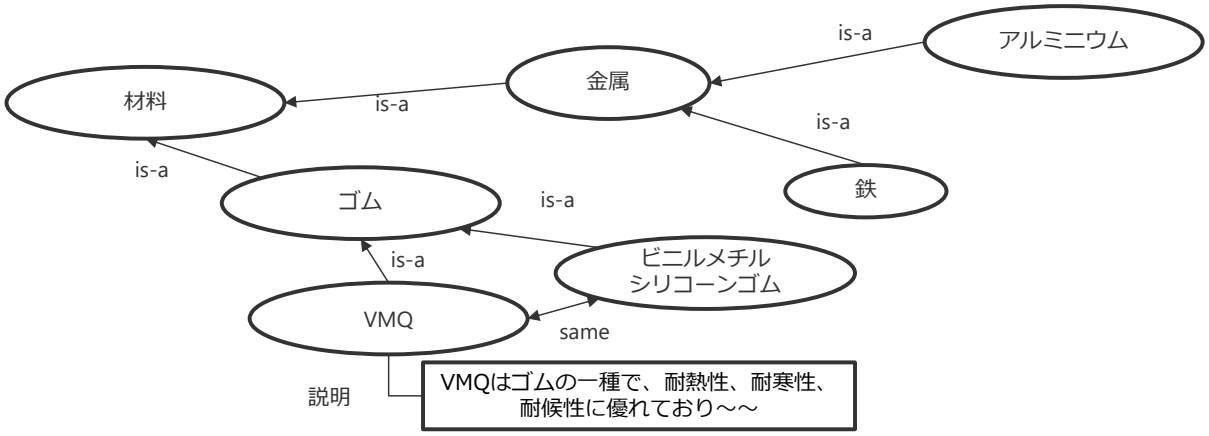

図 1: 知識グラフの概形

2 関連研究

知識グラフの構築手法に関連する研究として，以前に我々が投稿した論文 [2] にて提案した機械学習手法とルールベース手法を組み合わせた手法がある．しかし，同義語や上位下位概念の推定が困難であり，本研究で用いる知識グラフの構築には適さない．センテンス内における固有表現の出現順に着目したルールベースの関係性推定手法では，同一センテンスに出現するとは限らない同義語・上位下位概念の関係性の推定が困難なためである．また，仮に適用できるとしてもルールベース手法や機械学習手法ではルールの作成や学習のためのアノテーション工数が導入においてネックとなっている．

一方，知識グラフを自動構築し，RAG を組み合わせる手法として GraphRAG[3] などが一般的に知られている．GraphRAG では LLM を用いることで学習することなく，知識グラフを自動構築する手法が採用されている．本研究でも前述のルール作成やアノテーション工数の課題を解消できると考え，LLM を用いた手法に着目した．

LLM によって知識グラフを構築する手法には Carta らが提案する手法 [4] などがある．この研究では，固有表現が出現するコンテキストを要約した文章を生成し，その文章内の他の固有表現との関係性を LLM で推定する手法が提案されている．関係性はゼロショットのプロンプトで回答を生成することで推定しており，単純な関係性であれば推定できると述べられている．しかし，同義語・上位下位概念の関係性はドキュメント内で明記されていない場合や同一ドキュメント内に出現しない場合も多い．そのため，この手法をそのまま適用したとしても，図 1 のような知識グラフは構築できないと考えた．

そこで，必要とする知識グラフの構築に向けて，LLM を用いた同義語・上位下位概念の関係性推定手法の開発に取り組んだ．LLM を用いて関係性を推定する方法として，総当たりで語句のペアを作成し，それらのペアが同義語，もしくは上位下位概念の関係にあるかどうかの回答を生成させる手法（以下比較手法と呼ぶ）が考えられる．しかし，比較手法では語句の数が増えるほどペアの組み合わせは膨大となり，LLM で文章を生成する際に必要な処理時間がネックになる．LLM の文章生成にかかる時間が 1 回 10 秒，必要な文章生成が単語の数の 2 乗に比例すると仮定すると，数万件存在する社内の専門用語に関する知識グラフを作成する場合には，知識グラフの構築に数十万時間かかり，現実的ではないと判断した．そこで，本研究では，より処理時間が短い関係性の推定手法の開発に取り組んだ．

3 提案手法

本節では，開発した関係性の推定手法について述べる．図 2 は開発した手法を用いた知識グラフの構築プロセスを示している．まずは,「②説明文付与」の手法について説明し，その説明文を用いた「③同義語判定」,「④上位下位概念判定」の自動化手法について述べる．

3.1 固有表現への説明文付与

まずは，固有表現に対して説明文を付与する．この説明文は RAG の情報補完だけでなく，後述する同義語判定・上位下位概念判定にも用いられる．

LLM の学習に含まれていない専門用語の同義語と上位下位概念の判定には，ドキュメント内でどのように

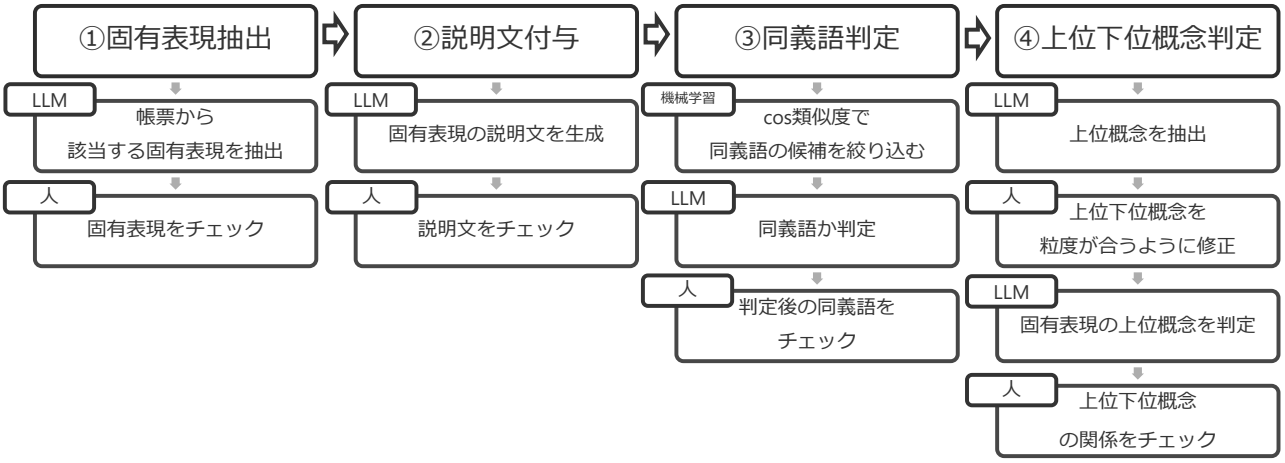

図 2: 知識グラフの構築プロセス

使われている語句なのかという情報が必要である．しかし，上位下位概念の判定では数十個の語句を同時に入力するため，トークン数制限やプロンプトの長文化による精度低下 [5] の観点から，出現している資料を全て入力することは現実的ではない．

そこで，LLM に図 3 のプロンプトを入力することで，語句に対して出現している資料をもとに 100 文字程度の説明文を生成した．実際の資料ではなくこの説明文を活用して以降の処理を行うことにより，数十件の固有表現を用いる処理であっても，LLM のトークン制限を超過する可能性は低くなる．

> あなたは自動車部品の設計者です.
> これから単語が与えられます.
> 参考文献を基にその単語を 100 文字程度で説明してください.
>
> # 参考文献
> { 固有表現が出現する参考文献のリスト }
>
> 単語：{ 固有表現 }

図 3: 説明文付与に用いたプロンプト

3.2 同義語判定の自動化手法

続いて，固有表現とそれの説明文を用いて同義語かどうかを判定する．2 節で述べたように，全ての固有表現から総当たりでペアを作成し，LLM で関係性を推定すると，処理にかかる時間が膨大なものとなってしまう．そこで，語句をベクトル化し，ベクトル同士の類似度で同義語となるペアの候補を絞り込んだ後に，LLM で判定する手法を導入した．

まずは，類似度による同義語の候補の絞り込みについて説明する．ここで，固有表現のベクトル表現として 3.1 節で生成した説明文をベクトル化したものを用いる．同義語には類似した説明文が生成されると考えたためである．これにより，周囲の文章から対象の固有表現のベクトルを学習することなく固有表現をベクトル化できる．なお，ベクトル化には Sentence-BERT[6] を用いた．Sentence-BERT は文章をより良質なベクトルに変換するため，BERT を改良したモデルである．

その後，固有表現に対して総当たりで cos 類似度を求め，各固有表現に対して類似度が 0.80 以上の固有表現を同義語の候補とする．cos 類似度の計算は LLM の文章生成と比べ計算時間が短く，総当たりで計算を行った場合でも現実的な処理時間となる．

続いて，上記のように選定した同義語の候補に対し，LLM で同義語かどうかを判定する．その際に図 4 のプロンプトを用いた．

なお，閾値を類似度が超えていれば同義語，下回っていれば同義語ではないと判定する方法では正確に同義語を推定することは困難であった．同じ上位概念を持つ語句など，同義語ではないが，説明文が似たものになる場合があるためである．実際，節 4.2 で述べる実験データで類似度を判定した際には，図 5 のように類似度が高い組み合わせの中にも同義語ではない組み合わせが多く混ざる結果となった．F1 値が最大となるように閾値を 0.90 と設定した場合でも F1 値は 0.44 と低い値となってしまう．一方，類似度が 0.80 以上のペアを同義語かどうかを LLM で判定させた場合の F1 値は 0.89 に改善する．

あなたは優れた言語学者です.
入力として与えられる 2 つの用語が同義語かどうか
step by step で考えた過程を答え,
最後に「同義語」・「同義語ではない」で答えなさい.

入力
{ 固有表現 1}
{ 固有表現 1 の説明 }

{ 固有表現 2}
{ 固有表現 2 の説明 }

図 4: 同義語判定出に用いたプロンプト

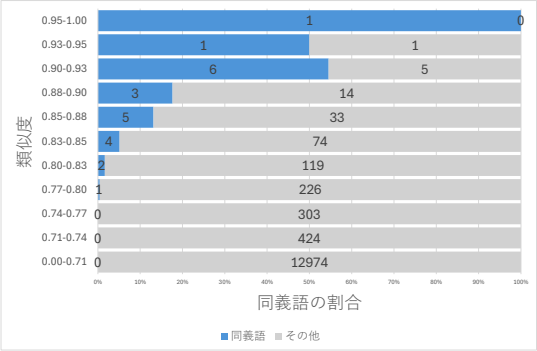

図 5: 説明文の類似度と同義語の関係

3.3 上位下位概念判定の自動化手法

固有表現とそれの説明文を用いて上位下位概念を判定する．上位下位概念の関係は方向性があるため，総当たりで判定を実施する場合，同義語判定のような方向性のない関係性よりも判定処理を行う回数が増えてしまう．そこで，語句のペアに対して一つ一つ判定するのではなく，多クラス分類としてタスクを設定することで判定処理の回数の削減に取り組んだ．

まずは，固有表現のリストから上位概念にあたる，特に曖昧な概念を表す語句を抽出する．上位概念の抽出は LLM で行い，その際には図 6 のプロンプトを用いた．なお，LLM が抽出した上位概念のリストは人が修正し，次の処理で用いる．

続いて，各固有表現に対して，抽出した上位概念のうちどれの下位概念となるか分類する．分類は LLM で行い，図 7 のプロンプトを用いた．

あなたは Knowledge Engineer です.
これから，語句リストが与えられます.
語句リストの言葉をカテゴライズできるようなより抽象的な語句を上位概念としてリストアップしてください.
上位概念は必ず語句リストから選択してください.

語句リスト
- { 固有表現 1}　説明: { 固有表現 1 の説明 }
- { 固有表現 2}　説明: { 固有表現 2 の説明 }
…

上位概念

図 6: 上位概念抽出に用いたプロンプト

あなたは Knowledge Engineer です.
これから，語句が与えられます.
その語句をより抽象的に表す言葉,
すなわち上位概念を上位概念リストから選んでください.

上位概念リスト
- { 固有表現 1}　説明: { 固有表現 1 の説明 }
- { 固有表現 2}　説明: { 固有表現 2 の説明 }
…

語句：
{ 固有表現 }　説明: { 固有表現の説明 }

上位概念：

図 7: 上位概念判定に用いたプロンプト

4 実験

3 節で紹介した手法とその比較対象としての手法に対して実験を行った．本節ではまず実験に用いたデータ・モデルを説明し，その後，実験結果とそれに対する考察を述べる．

4.1 実験に用いるデータ・モデル

実験データには「樹脂」についての新入社員向けの教育資料を用いた．実験データは主に自然文章と図で記載された 81 ページの資料である．固有表現抽出では

「材料」「製法」「性質」を表す固有表現を対象に抽出し，人の手で間違いを修正した．その結果，実験データには固有表現が 169 件含まれていた．これらの固有表現に対して，同義語・上位下位概念の関係性を推定する実験を実施した．

なお，比較手法に対しては，同義語・上位下位概念の関係にある固有表現のペア全て（正例）と，それぞれの関係にないペア 100 件（負例）を用いて実験を行い，精度と処理時間を算出した．

実験で LLM を用いる処理では，OpenAI 社の GPT-4[7] をモデルとして用いる．また，日本語用 Sentence-BERT として大規模日本語コーパスで事前学習されたモデル [8] を用いた．

4.2 実験結果

同義語判定手法の実験結果は表 1 のようになり，提案手法の精度は比較手法に対してわずかに下回る結果となった．特に Recall の低下による同義語の見逃しは，修正する際に人にかかる労力が大きいため，要因の分析・改善が必要である．しかし，比較手法と比べても大幅な精度低下はしておらず，十分に実用可能な手法であると言える．

上位下位概念判定の提案手法の正解率は 0.78 となった．多クラス分類にしたことや上位下位概念の判定というタスクの難しさにより，同義語推定よりも低い精度となったと考えている．今後，上位下位概念の推定精度がどの程度 RAG の回答精度に影響を及ぼすか検証し，実用性の有無を検討する．

処理時間に関しては表 2 に示す結果となり，同義語判定，上位下位概念判定のいずれも提案手法の方が大幅に短い．同義語判定は約 15 万秒から約 5,400 秒に，上位下位概念判定は約 30 万秒から約 3,300 秒に短縮されている．今後，より大きなデータセットを扱うことを考えたとしても，実用的な処理時間で知識グラフの構築が可能な手法を開発できたと言える．

4.3 考察

まずは同義語判定についての考察を述べる．同義語判定の提案手法の Recall が比較手法を下回る値となった原因は，類似度の閾値 0.80 を下回る同義語のペアが存在してしまったためである．今回の実験データでは「アルミニウム」と同義語である「Al」の類似度が 0.796 となり，僅かに閾値を下回ってしまった.「アルミニウム」の説明文には「使用可能温度は約 250 ℃までで、高温になると強度が低下します。」という文言が記載され，同義語である「Al」には同様の文言は記載されなかったことが類似度低下の要因である．この文言は「アルミニウム」の周辺文章に記載された内容のものであり，周辺文章の記載内容が偏ると同義語であっても見逃してしまう可能性があると言える．今後，類似度の閾値を最適化し，より見逃しが少なるよう改善したい．また，見逃しではなく過検出の例となるが，上位下位概念の関係にある固有表現のペアが同義語と誤答される例があった．例えば、「炭素鋼」とその一種である「S45」を同義語と判定してしまう．LLM が上位下位概念を同義語に含んでいることが懸念されるため，プロンプトを修正し，タスクをより明確に説明するよう修正する予定である．

続いて，上位下位概念の判定についての考察を述べる．上位下位概念の判定結果としては中間概念が存在する例で誤判定が見られた．例えば,「ポリエチレンテレフタレート」の上位概念を「エンジニアリングプラスチック」ではなく「熱可塑性樹脂」（エンジニアリングプラスチックは熱可塑性樹脂の一種）と判定してしまっている．これは，上位下位概念に中間概念と言えるような概念が挟まり，多段的な構造になることを想定できていないためである．そのため，今後は多段的な構造にも対応できるよう，手法の改善に取り組む予定である．具体的には，LLMs4OL[9] のように，上位下位概念と判定された概念同士で上位下位概念の判定を実施する．また，比較手法では見られない，LLM の不安定性による悪影響も見られた．上位概念のリストにない言葉を生成し，上位概念として判定する場合である．温度パラメータを下げて安定化を図ったが，本論文で用いているモデル・プロンプトでは改善に至らなかった．今後，プロンプトやモデルを変更して改善するかどうか検討したい．

また，構築した知識グラフをどのようにして RAG に組み込むと効果的に回答精度を高められるのかどうかも検討していくつもりである．

5 結論

本研究では，開発期間の短縮を目指し，専門外の知識に対応するためのチャットボットシステムを開発している．特に，生成 AI が専門用語を学習していない場合や，質問文で使われる語句が具体的・曖昧過ぎる場合に，正確な回答を生成できないという課題に取り組んでいる．この課題を解決するために，知識グラフを用いて語句の説明文や上位下位概念，同義語の情報を補足する方法を検討している．

知識グラフを用いるためには構築コスト低減が必要である．そのため，知識グラフ構築プロセスを自動化する LLM を活用した手法を開発した．その結果，同義語と上位下位概念の関係性を効率的に推定可能となった．実験の結果，提案手法が処理時間の短縮において

表 1: 同義語判定の実験結果

	Recall	Precision	F1 値
比較手法	0.91	1.00	0.95
提案手法	0.87	0.91	0.89

表 2: 上位下位概念判定の実験結果

		処理時間 [s]
同義語判定	比較手法	152,992
	提案手法	5,427
上位下位概念判定	比較手法	305,296
	提案手法	3,335

有効な手法だと示された．一方で，推定精度については今後，知識グラフを用いた RAG の回答精度の影響について検証し，実用的な精度がどうか検証していく予定である．

参考文献

[1] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, Vol. 33, pp. 9459–9474. Curran Associates, Inc, 2020.

[2] 森川祐介, 福田悠貴, 仁禮和男, 藤井直希, 関根聡, 松本裕治, 古崎晃司. 自動車部品オントロジー構築のための専門知識抽出手法の開発. 人工知能学会第二種研究会資料, Vol. 2023, No. SWO-061, p. 05, 2023.

[3] Darren Edge, Ha Trinh, Newman Cheng, Joshua Bradley, Alex Chao, Apurva Mody, Steven Truitt, and Jonathan Larson. From local to global: A graph RAG approach to query-focused summarization. Publisher: arXiv Version Number: 1, 2024.

[4] Salvatore Carta, Alessandro Giuliani, Leonardo Piano, Alessandro Sebastian Podda, Livio Pompianu, and Sandro Gabriele Tiddia. Iterative zero-shot LLM prompting for knowledge graph construction. arXiv preprint arXiv:2307.01128, 2023.

[5] Tianle Li, Ge Zhang, Quy Duc Do, Xiang Yue, and Wenhu Chen. Long-context LLMs struggle with long in-context learning. arXiv preprint arXiv:2404.02060, 2024. version: 1.

[6] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using siamese BERT-networks. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pp. 3982–3992. Association for Computational Linguistics, 2019.

[7] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. Gpt-4 technical report. arXiv preprint arXiv:2303.08774, 2023.

[8] sonoisa/sentence-bert-base-ja-mean-tokens-v2 · hugging face, https://huggingface.co/sonoisa/sentence-bert-base-ja-mean-tokens-v2, 2021.

[9] Hamed Babaei Giglou, JenniferD ’ Souza, Sören Auer. LLMs4ol: Large language models for ontology learning. In Terry R. Payne, Valentina Presutti, Guilin Qi, María Poveda-Villalón, Giorgos Stoilos, Laura Hollink, Zoi Kaoudi, Gong Cheng, and Juanzi Li, editors, *The Semantic Web – ISWC 2023*, pp. 408–427. Springer Nature Switzerland, 2023.